


**Στατιστική Μοντελοποίηση και Αναγνώριση προτύπων (ΤΗΛ 311)**  
**Αναφορά 1ου Σέτ Ασκήσεων**

**Θέμα 1ο : Principal Component Analysis (PCA)**

Στην 1η άσκηση εφαρμόστηκε η unsupervised μέθοδος PCA η οποία αναπαριστά τα N-διαστατά δεδομένα σε ένα χώρο λιγότερων διαστάσεων. Ο στόχος της χρήσης της συγκεκριμένης μεθόδου είναι να γίνει κατανοητή η βασική αρχή λειτουργίας της η οποία είναι να μειωθούν οι βαθμοί ελευθερίας μειώνοντας έτσι τις χωρικές και χρονικές πολυπλοκότητες.


Μέρος 1ο:

Άρχικά γίνεται φόρτωση των δεδομένων μέσω της εντολής load και η απεικόνιση τους στον δισδιάστατο χώρο (2D).



*Σχήμα 1α : Τα αρχικά δείγματα*

Στη συνέχεια υλοποιώντας την συνάρτηση featureNormalize πραγματοποιείται η προεπεξεργασία των δεδομένων κανονικοποιώντας τα δείγματα με μέση τιμή μηδέν και διασπορά ίση με 1 ώστε δεδομένα διαφορετικών κλιμάκων να μην οδηγήσουν σε παραπλανητικά στοιχεία και να συνεισφέρουν ισότιμα στην ανάλυση. Στο σχήμα 1β φαίνονται τα κανονικοποιημένα δεδομένα, συγκρίνοντας τα με τα αρχικά δείγματα, παρατηρείται ότι τα δεδομένα απεικονίζονται σε μικρότερη κλίμακα από ότι στην αρχή.




Σχήμα 1β : Κανονικοποίηση των δεδομένων

Κατόπιν υλοποιώντας τον αλγόριθμο PCA υπολογίστικαν οι κύριες συνιστώσες του αλγορίθμου ως τα ιδιοδιανύσματα με χρήση της μεθόδου singular value decomposition. Κατά την υλοποίηση του αλγορίθμου PCA χρησιμοποιήθηκε ο παρακάτω τύπος για τον υπολογισμό του πίνακα συνδιασποράς  $\Sigma$  :

$$\Sigma = \frac{1}{m} X^T X$$
 , όπου  $X \in \mathbb{R}^{m \times n}$  είναι ένας πίνακας όπου κάθε γραμμή αντιστοιχεί σε ένα παράδειγμα με  $n$  χαρακτηριστικά.

Στο σχήμα 2 απεικονίζονται οι κύριες συνιστώσες του αλγορίθμου ως οι κατευθύνσεις των δεδομένων οι οποίες αντιπροσωπεύουν το μέγιστο ποσό διακύμανσης δηλαδή οι γραμμές οι οποίες συλλέγουν τις περισσότερες πληροφορίες των δεδομένων.



Σχήμα 2: Οι κύριες συνιστώσες των δεδομένων

Ακολούθως υπολογίζεται η συνεισφορά που έχει κάθε κύρια συνιστώσα στην συνολική διακύμανση μέσω του τύπου :


$PC_{variance} = \frac{eigenVal}{\sum(eigenVal)}$  , δηλαδή η συνεισφορά κάθε συνιστώσας είναι ίση με το πηλίκό της ιδιοτιμής κάθε συνιστώσας προς το συνολικό άθροισμα των ιδιοτιμών όλων των συνιστωσών.

Επιπλέον μειώνεται η διάσταση των δεδομένων από 2D σε 1D στα αρχικά δείγματα υλοποιώντας τη συνάρτηση projectData η οποία χρησιμοποιώντας έναν γραμμικό μετασχηματισμό προβάλλει τα δεδομένα σε λιγότερες διαστάσεις. Ο τύπος του γραμμικού μετασχηματισμού που χρησιμοποιήθηκε είναι :

$$Z_i = U^T X_i \text{ όπου } X_i \text{ είναι κάθε δείγμα.}$$

Στη συνέχεια υλοποιώντας τη συνάρτησης recoverData πραγματοποιείται η ανάκτηση των αρχικών δειγμάτων προσεγγιστικά αναπαράγοντάς τα ξανά στον αρχικό χώρο υψηλών διαστάσεων(2D). Αυτό γίνεται με την προβολή τους πάνω σε όλες τις κύριες συνιστώσες (principal components) με τον ακόλουθο μετασχηματισμό και φαίνεται στο σχήμα 3:

$$X_{rec} = U \cdot z$$



Σχήμα 3 Τα αρχικά δείγματα προεπεξεργασμένα (μπλέ κύκλοι) και τα δείγματα ανακτόμενα (κόκκινοι κύκλοι)

## Μέρος 2ο:

Γενικεύοντας την μέθοδο PCA ,χρησιμοποιήθηκαν 5000 εικόνες προσώπων από το αρχείο 'ex1faces.mat' με σκοπό να εφαρμοστούν οι προαναφερθείσες συναρτήσεις σε ένα γενικευμένο dataset.

Αρχικά σχεδιάζονται οι 100 πρώτες εικόνες από το dataset με τη χρήση της συνάρτησης `displayData()` και πραγματοποιείται προεπεξεργασία των δεδομένων εφαρμόζοντας κανονικοποίηση με μέση τιμή μηδέν και διασπορά ίση με 1 χρησιμοποιώντας τη συνάρτηση `featureNormalize()`.



*Σχήμα 4: Οι 100 πρώτες εικόνες*

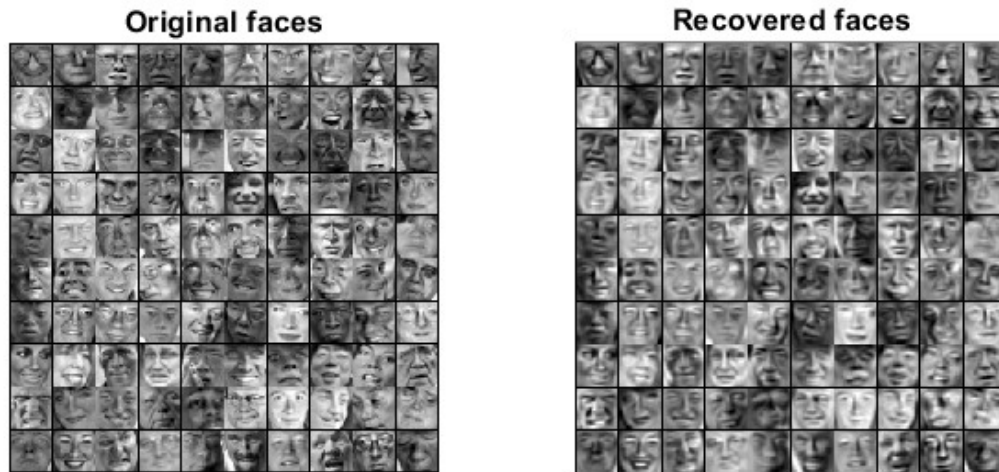
Στη συνέχεια με χρήση της συνάρτησης `mgprca()` υπολογίζονται οι κύριες συνιστώσες των δεδομένων και απεικονίζονται στο σχήμα 5 οι 36 κύριες συνιστώσες χρησιμοποιώντας της συνάρτησης `displayData()`.



*Σχήμα 5: Οι 36 κύριες συνιστώσες*

Κατόπιν εφαρμόζοντας την συνάρτηση `projectData()` μειώνονται η διάσταση των δειγμάτων χρησιμοποιώντας τις 100 πρώτες κύριες συνιστώσες.

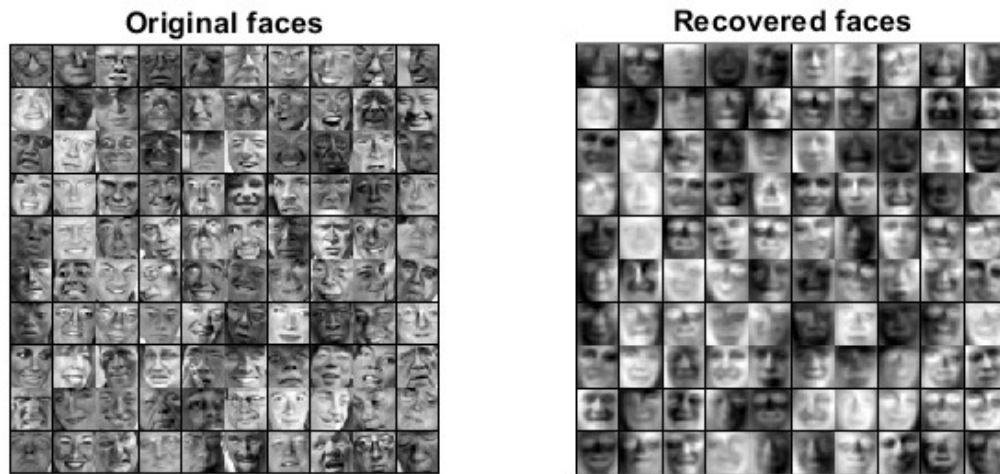
Τέλος αναπαριστώνται στο σχήμα 6 τα δείγματα μειωμένης διάστασης αφού προηγουμένως έχουν προβληθεί στον αρχικό χώρο χρησιμοποιώντας τη συνάρτηση `recoverData()`.



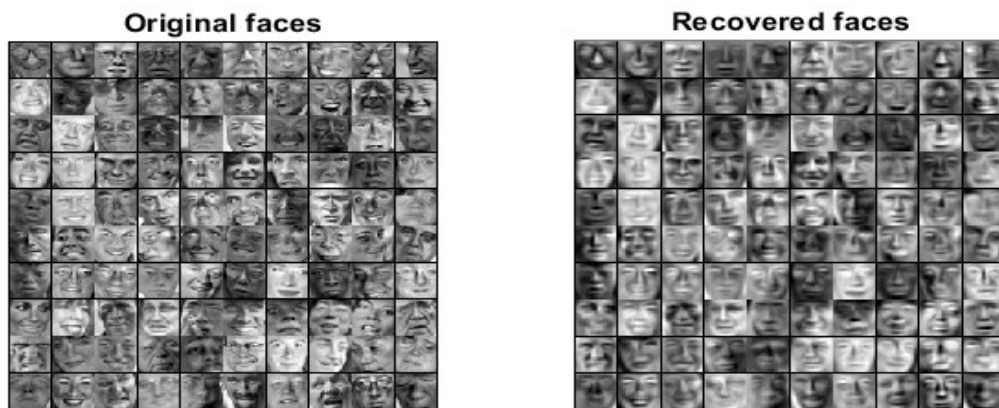
*Σχήμα 6: Οι αρχικές εικόνες σε αντιδιαστολή με τις ανακτημένες εικόνες*

Στο σχήμα 6 παρατηρείται ότι η ανάκτηση των δεδομένων έχει επιτευχθεί καθώς η μέθοδος PCA χρησιμοποιεί για την προβολή και ανάκτηση των δεδομένων τις κύριες συνιστώσες οι οποίες περιέχουν τη περισσότερη πληροφορία σε όσον το δυνατόν λιγότερα ιδιοδιανύσματα.

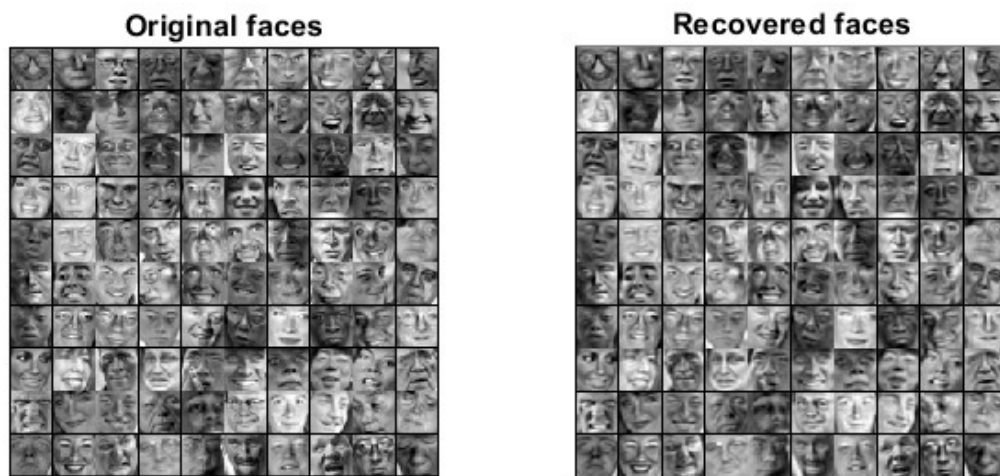
Επαναλαμβάνοντας την παραπάνω διαδικασία για διαφορετικό αριθμό από κύριες συνιστώσες , συγκεκριμένα για  $K = 10, 50, 200$  σχεδιάζονται τα ανακτημένα πρόσωπα σε αντιπαραβολή με τα αρχικά. Παρατηρείται ότι χρησιμοποιώντας μεγαλύτερο αριθμό κύριων συνιστωσών η λεπτομέρεια των προσώπων αυξάνεται αφού παρέχεται περισσότερη πληροφορία μέσα απο τα ιδιοδιανύσματα.



Σχήμα 7 : Κύριες συνιστώσες  $K = 10$



Σχήμα 8: Κύριες συνιστώσες  $K = 50$



Σχήμα 9 : Κύριες συνιστώσες  $K = 200$

## Θέμα 2ο : Ταξινομητής LDA (Linear Discriminant Analysis)

Είναι γνωστό ότι οι εκ των προτέρων( a priori) πιθανότητες των δύο κλάσεων είναι ίσες δηλαδή ισχύει ότι  $P(\omega_1)=P(\omega_2)=\frac{1}{2}$  .

$$\mu_1 = \begin{bmatrix} -5 \\ 5 \end{bmatrix} , \quad \mu_2 = \begin{bmatrix} 10 \\ 15 \end{bmatrix}$$

$$\Sigma_1 = \begin{bmatrix} 11 & 9 \\ 9 & 11 \end{bmatrix} , \quad \Sigma_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

Για τον υπολογισμό του  $S_w$  θα χρησιμοποιήσω τον ακόλουθο τύπο :

$$S_w = \sum_{i=1}^M P_i \cdot \Sigma_i , \quad \text{όπου } M \text{ είναι ο αριθμός των κλάσεων.}$$



Άρα

$$S_w = \sum_{i=1}^2 P_i \cdot \Sigma_i = \frac{1}{2} (\Sigma_1 + \Sigma_2) = \begin{bmatrix} \frac{13}{2} & \frac{9}{2} \\ \frac{9}{2} & \frac{13}{2} \end{bmatrix}$$

Για την εύρεση του αντίστροφου πίνακα  $S_w^{-1}$  χρησιμοποιείται ο παρακάτω τύπος :

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} = \frac{1}{a \cdot d - b \cdot c} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Επομένως ο πίνακας  $S_w^{-1}$  είναι ίσο με :

$$S_w^{-1} = \begin{bmatrix} \frac{13}{2} & \frac{9}{2} \\ \frac{9}{2} & \frac{13}{2} \end{bmatrix}^{-1} = \frac{1}{\frac{169}{4} - \frac{81}{4}} \begin{bmatrix} \frac{13}{2} & -\frac{9}{2} \\ -\frac{9}{2} & \frac{13}{2} \end{bmatrix} = \frac{1}{22} \begin{bmatrix} \frac{13}{2} & -\frac{9}{2} \\ -\frac{9}{2} & \frac{13}{2} \end{bmatrix} \quad (1)$$

Το διάνυσμα προβολής για  $M = 2$  υπολογίζεται με βάση το τύπο :

$$w = S_w^{-1} (\mu_1 - \mu_2) \quad (2)$$

Άρα το διάνυσμα προβολής είναι,

$$(1), (2) \Rightarrow w = \frac{1}{22} \begin{bmatrix} \frac{13}{2} & -\frac{9}{2} \\ -\frac{9}{2} & \frac{13}{2} \end{bmatrix} \begin{bmatrix} -15 & -10 \end{bmatrix} = \begin{bmatrix} \frac{13}{2}(-15) + (-\frac{9}{2})(-10) \\ (-\frac{9}{2})(-15) + \frac{13}{2}(-10) \end{bmatrix} = \frac{1}{22} \begin{bmatrix} -\frac{105}{2} \\ \frac{5}{2} \end{bmatrix} = \begin{bmatrix} -\frac{105}{44} \\ \frac{5}{44} \end{bmatrix} \Rightarrow$$

$$w = \begin{bmatrix} -\frac{105}{44} \\ \frac{5}{44} \end{bmatrix}$$


### Θέμα 3: Linear Discriminant Analysis (LDA) vs PCA

Στην 3η άσκηση εφαρμόστηκε η supervised μέθοδος LDA η οποία αναπαριστά τα N-διαστατά δεδομένα σε ένα χώρο λιγότερων διαστάσεων. Όμως σε αντίθεση με τη μέθοδο PCA υπολογίζει τις κατευθύνσεις οι οποίες αντιπροσωπεύουν τους άξονες που μεγιστοποιούν τον διαχωρισμό μεταξύ των πολλαπλών κλάσεων.

#### Μέρος 1ο:


Αρχικά φορτώνονται τα δεδομένα μέσω της εντολής `load` και δημιουργούνται οι μεταβλητές `c,X` οι οποίες περιέχουν την κλάση και τα χαρακτηριστικά διανύσματα αντίστοιχα. Στη συνέχεια πραγματοποιείται κανονικοποίηση των δειγμάτων με μέση τιμή μηδέν και διασπορά ίση με ένα χρησιμοποιώντας τη συνάρτηση `featureNormalize` που είχε υλοποιηθεί στο θέμα 1, παράλληλα

σχεδιάζονται οι κλάσεις στο σχήμα 10 με διαφορετικό χρώμα η κάθεμία έτσι ώστε να γίνονται εύκολα διαχωρίσιμες.




Σχήμα 10 : Αρχικά δείγματα κανονικοποιημένα

Κατόπιν υλοποιείται η συνάρτηση `fisherLinearDiscriminant` έτσι ώστε να εφαρμοστεί ο αλγόριθμος LDA για προβλήματα δύο κλάσεων. Δημιουργούνται δεδομένα μειωμένης διάστασης(1D) με την υλοποίηση της συνάρτησης `projectDataLDA` και ύστερα ανακατασκευάζονται τα δείγματα μειωμένης διάστασης στον 2D χώρο προβάλλοντας τα πάνω στην κατεύθυνση του διανύσματος προβολής LDA . Στο σχήμα 11 φαίνονται τα δείγματα μειωμένης διάστασης όπως προβάλλονται στον 2D χώρο μαζί με τα αρχικά δείγματα και παρατηρείται ότι έχει επιτευχθεί ο πλήρης διαχωρισμός των κλάσεων.



Σχήμα 11 : Αρχικά δείγματα κανονικοποιημένα και τα ανακτημένα δείγματα με τη χρήση της μεθόδου LDA


Εφαρμόζοντας την αντίστοιχη διαδικασία μείωσης διάστασης με τη μέθοδο PCA φαίνονται στο σχήμα 12 ότι δεν έχει καταστεί ικανός ο διαχωρισμός των κλάσων κάτι το οποίο είναι λογικό αφού η συγκεκριμένη μέθοδος δεν διαχωρίζει τα δεδομένα με βάση τις ετικέτες τους αλλά με βάση τη διασπορά τους. Συγκρίνοντας την τελευταία μέθοδο με τη μέθοδο διαχωρισμού LDA συμπεραίνεται ότι η μέθοδος linear discriminant analysis προτιμάται για data set τα οποία είναι επιθυμητό να διαχωριστούν με βάση κάποια labels έναντι της μεθόδου principal components analysis κατά την οποία δίνεται έμφαση στην εύρεση των κύριων συνιστωσών των δεδομένων δηλαδή τα δείγματα με τη μεγαλύτερη διασπορά.



Σχήμα 12 : Αρχικά δείγματα και ανακτόμενα δείγματα με τη χρήση της μεθόδου PCA


## Μέρος 2ο:

Στο 2ο μέρος χρησιμοποιήθηκε ως dataset η βάση δεδομένων Fisher's Iris η οποία περιέχει 50 δείγματα απο τρία διαφορετικά είδη της οικογένειας λουλουδιών Iris και κάθε δείγμα αποτελείται από τέσσερα χαρακτηριστικά των λουλουδιών και συγκεκριμένα το μήκος και το πλάτος (σε cm) των σέπαλων και των ανθόφυλλων. Τα δεδομένα φορτώνονται μέσω της εντολής `load` , κανονικοποιούνται με μέση τιμή μηδέν και διασπορά ίση με 1 και σχεδιάζονται τα 2 πρώτα χαρακτηριστικά στο σχήμα 13 χρησιμοποιώντας ξεχωριστά χρώματα για κάθε κλάση.



Σχήμα 13 : Αρχικά δεδομένα από τη βάση δεδομένων iris

Στη συνέχεια υλοποιήθηκε η συνάρτηση `mgLDA` μειώνοντας τον χώρο των χαρακτηριστικών στον δισδιάστατο χώρο και εφαρμόστηκαν τα διανύσματα προβολής που είχαν υπολογιστεί με την `mgLDA` πάνω στα αρχικά δείγματα με τη συνάρτηση `projectDataLDA` ώστε να μειωθεί η διάσταση του σε 2. Τα ιδιοδιανύσματα υπολογίζονται με χρήση της μεθόδου `eigendecomposition` σε αντίθεση με τον υπολογισμό του στο προηγούμενο ερώτημα.



Σχήμα 14 : Ανακτόμενα δείγματα με τη χρήση της μεθόδου LDA

Στο σχήμα 14 παρατηρείται ότι έχει επιτύχει ο πλήρης διαχωρισμός των κλάσεων, το οποίο είναι και ο λόγος που χρησιμοποιούμε τη μέθοδο LDA έναντι της μεθόδου PCA.

#### Θέμα 4: Bayes

Για την εύρεση του συνόρου απόφασης θα χρησιμοποιήσω τη συνάρτηση διάκρισης

$$g_i(x) = P(\omega_i|x) = \frac{p(x|\omega_i) \cdot p(\omega_i)}{\sum_{j=1}^c p(x|\omega_j) \cdot p(\omega_j)}$$

Ειδικότερα για  $g_i(x) > g_j(x)$  με  $i \neq j$  αποφασίζω  $\omega_i$  αλλιώς  $\omega_j$

Ακόμη η συνάρτηση διάκρισης μπορεί να μετασχηματιστεί με τη χρήση της συνάρτησης  $\ln$  διότι η  $\ln$  είναι γνησίως αύξουσα συνάρτηση, κατά συνέπεια ο διαχωρισμός μεταξύ των κλάσεων είναι αμετάβλητος. Επίσης ο πολλαπλασιασμός σταθερών με όλες τις συναρτήσεις διάκρισης δεν θα επηρεάσει το αποτέλεσμα του classification. Άρα η παρακάτω συνάρτηση  $g_i(x)$  είναι ισοδύναμη με την αρχική συνάρτηση.

$$g_i(x) = P(\omega_i|x) = \ln(p(x|\omega_i)) + \ln(p(\omega_i))$$

Γνωρίζουμε όμως ότι οι κλάσεις περιγράφονται από τις ακόλουθες κανονικές κατανομές,

$$p(x|\omega_i) = N(\mu_i, \Sigma_i)$$

με μέσες τιμές ίσες με

$$\mu_1 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}, \quad \mu_2 = \begin{bmatrix} 6 \\ 6 \end{bmatrix}$$

με πίνακες συνδιασποράς και τις ορίζουσες ίσες με»

$$\Sigma_1 = \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix}, \quad \Sigma_2 = \begin{pmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{pmatrix}, \quad |\Sigma_1| = |\Sigma_2| = \frac{1}{1.28}$$

Άρα προκύπτει ότι η discriminant function  $g_i(x)$  μπορεί να αναλυθεί ως εξής:

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1}(x - \mu_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$

Πραγματοποιώντας ορισμένες προσαρμοστικές ιδιοτητες στην παραπάνω συνάρτηση, η  $g_i(x)$  μπορεί να πάρει τη μορφή μίας τετραγωνικής συνάρτησης

$$g_i(x) = x^T W_i x + w_{i0}$$

με

$$W_i = -\frac{1}{2} \Sigma_i^{-1}$$

$$W_i = \Sigma_i^{-1} \mu_i$$

$$w_{i0} = -\frac{1}{2} \mu_i^T \Sigma_i^{-1} \mu_i - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$

Οι αντιστροφικοί πίνακες των πίνακων συνδιασποράς υπολογίζονται με βάση τον τύπο που αναπτύχθηκε στο θέμα 2ο και είναι ίσοι με

$$\Sigma_1^{-1} = \frac{1}{1.28} \begin{pmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{pmatrix}, \quad \Sigma_2^{-1} = \frac{1}{1.28} \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix}$$

Στη συνέχεια

$$W_1 = -\frac{1}{2} \Sigma_1^{-1} = -\frac{1}{2.56} \begin{pmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{pmatrix}$$

$$W_2 = -\frac{1}{2} \Sigma_2^{-1} = -\frac{1}{2.56} \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix}$$

$$w_1 = \Sigma_1^{-1} \mu_1 = \frac{1}{1.28} \begin{pmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{pmatrix} \begin{bmatrix} 3 \\ 3 \end{bmatrix} = \begin{bmatrix} \frac{3.6}{1.28} + \frac{1.2}{1.28} \\ \frac{1.2}{1.28} + \frac{3.6}{1.28} \end{bmatrix} = \begin{bmatrix} \frac{4.8}{1.28} \\ \frac{4.8}{1.28} \end{bmatrix}$$

$$w_2 = \Sigma_2^{-1} \mu_2 = \frac{1}{1.28} \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix} \begin{bmatrix} 6 \\ 6 \end{bmatrix} = \begin{bmatrix} \frac{7.2}{1.28} - \frac{2.4}{1.28} \\ -\frac{2.4}{1.28} + \frac{7.2}{1.28} \end{bmatrix} = \begin{bmatrix} \frac{4.8}{1.28} \\ \frac{4.8}{1.28} \end{bmatrix}$$

Με χρήση του συνόρου απόφασης που αναπτύχθηκε παραπάνω για  $g_1(x) > g_2(x)$  , αποφασίζω  $\omega_1$  αλλιώς  $\omega_2$  . Άρα,

$$\begin{aligned} g_1(x) > g_2(x) &\Leftrightarrow x^T W_1 x + w_1^T x + w_{10} > x^T W_2 x + w_2^T x + w_{20} \Leftrightarrow \\ x^T W_1 x - \frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 - \frac{1}{2} \ln |\Sigma_1| + \ln P(\omega_1) &> x^T W_2 x - \frac{1}{2} \mu_2^T \Sigma_2^{-1} \mu_2 - \frac{1}{2} \ln |\Sigma_2| + \ln P(\omega_2) \Leftrightarrow \\ x^T (W_1 - W_2) x - \frac{1}{2} (\mu_1^T \Sigma_1^{-1} \mu_1 - \mu_2^T \Sigma_2^{-1} \mu_2) + \ln \frac{P(\omega_1)}{P(\omega_2)} &> 0 \quad (I) \end{aligned}$$

$$W_1 - W_2 = -\frac{1}{2.56} \begin{pmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{pmatrix} - \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix} = -\frac{1}{2.56} \begin{pmatrix} 0 & 0.8 \\ 0.8 & 0 \end{pmatrix} = \begin{pmatrix} 0 & -\frac{0.8}{2.56} \\ -\frac{0.8}{2.56} & 0 \end{pmatrix}$$

$$\mu_1^T \Sigma_1^{-1} \mu_1 = (3 \ 3) \left( \frac{1}{1.28} \right) \begin{pmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{pmatrix} \begin{bmatrix} 3 \\ 3 \end{bmatrix} = (3 \ 3) \begin{bmatrix} \frac{4.8}{1.28} \\ \frac{4.8}{1.28} \end{bmatrix} = \frac{6 \cdot 4.8}{1.28} = \frac{28.8}{1.28}$$

$$\mu_2^T \Sigma_2^{-1} \mu_2 = (6 \ 6) \left( \frac{1}{1.28} \right) \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix} \begin{bmatrix} 6 \\ 6 \end{bmatrix} = (6 \ 6) \begin{bmatrix} \frac{4.8}{1.28} \\ \frac{4.8}{1.28} \end{bmatrix} = \frac{12 \cdot 4.8}{1.28} = \frac{57.6}{1.28}$$



$$\begin{aligned}
(I) \Rightarrow x^T \begin{pmatrix} 0 & -\frac{0.8}{2.56} \\ -\frac{0.8}{2.56} & 0 \end{pmatrix} x - \frac{1}{2} \cdot \frac{28.8}{1.28} + \ln \frac{P(\omega_1)}{P(\omega_2)} > 0 \Leftrightarrow (x_1 \ x_2) \begin{pmatrix} 0 & -\frac{0.8}{2.56} \\ -\frac{0.8}{2.56} & 0 \end{pmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \frac{1}{2} \cdot \frac{28.8}{1.28} + \ln \frac{P(\omega_1)}{P(\omega_2)} > 0 \Leftrightarrow \\
(x_1 \ x_2) \begin{bmatrix} (-\frac{0.8}{2.56})x_2 \\ (-\frac{0.8}{2.56})x_1 \end{bmatrix} - 11.25 + \ln \frac{P(\omega_1)}{P(\omega_2)} > 0 \Leftrightarrow (-\frac{0.8}{1.28})x_1x_2 - 11.25 + \ln \frac{P(\omega_1)}{P(\omega_2)} > 0 \Leftrightarrow \\
x_1x_2 < 18 + 1.6 \cdot \ln \frac{P(\omega_1)}{P(\omega_2)}
\end{aligned}$$

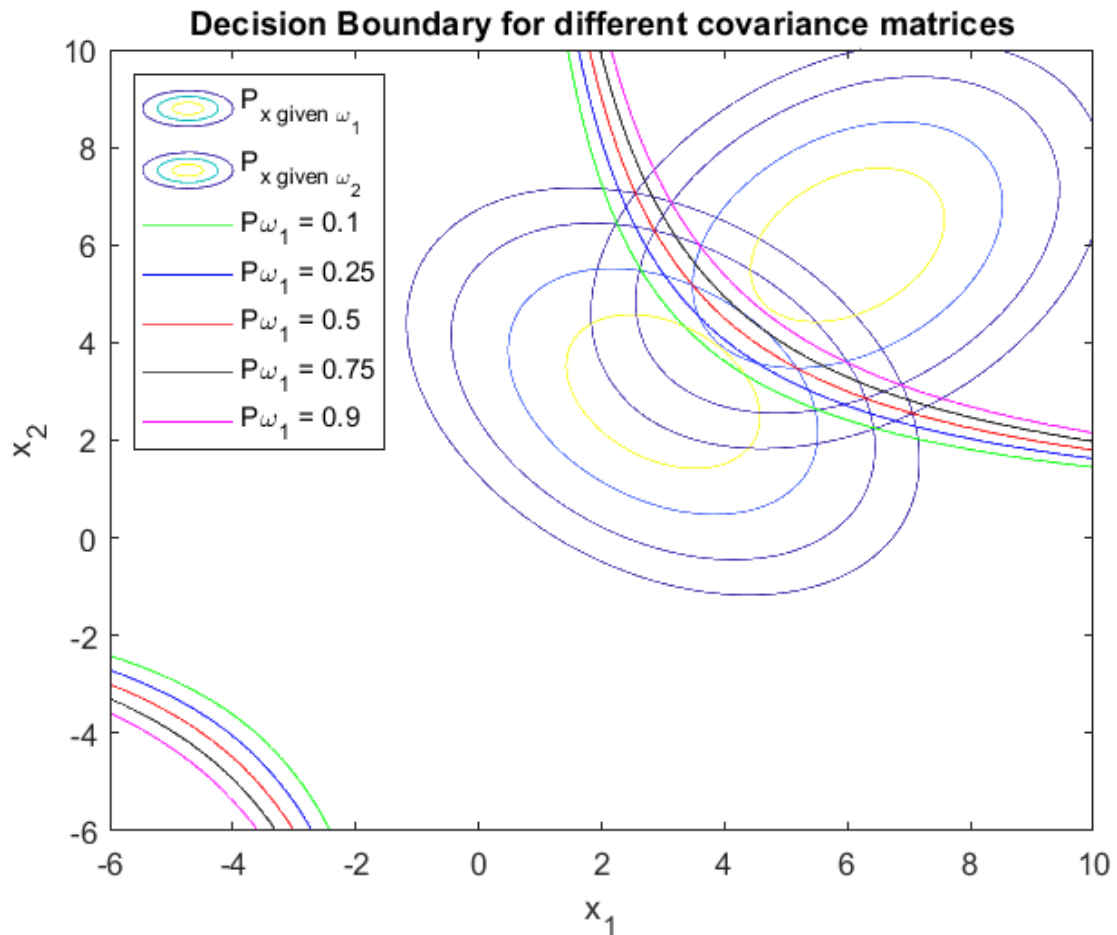
Άρα το σύνоро απόφασης είναι ότι για  $x_1x_2 < 18 + 1.6 \cdot \ln \frac{P(\omega_1)}{P(\omega_2)}$  αποφασίζω  $\omega_1$  αλλιώς  $\omega_2$ .

Στο σχήμα 16 έχουν σχεδιαστεί μερικές ισοϋψείς καμπύλες των δεσμευμένων πιθανοτήτων

$p(x|\omega_i) \in \mathcal{R}$  για κάθε κλάση  $i$  μαζί με τα σύνορα απόφασης για τις ακόλουθες τιμές των a-priori πιθανοτήτων  $P(\omega_1) = 0.1, 0.25, 0.5, 0.75, 0.9$  και  $P(\omega_2) = 1 - P(\omega_1)$ . Τα σύνορα απόφασης που προκύπτουν είναι ορθογώνιες υπερβολές, το οποίο επαληθεύεται τόσο από τον θεωρητικό τύπο όσο και από τη σχεδίαση τους. Επίσης το σύνορο απόφασης μπορεί να γραφεί ως:

$$x_1x_2 < 18 + 1.6 \cdot \ln \frac{P(\omega_1)}{1 - P(\omega_1)} \quad (a)$$

Παρατηρείται στο σχήμα 16 ότι αυξάνοντας την εκ των προτέρων πιθανότητα  $P(\omega_1)$  μειώνεται προφανώς η εκ των προτέρων πιθανότητα  $P(\omega_2)$  και το σύνορο απόφασης μετατίθεται σε πιο υψηλές τιμές αφού αυξάνεται το δεξιό μέλος της ανισότητας α. Επίσης όσο αυξάνεται η  $P(\omega_1)$  το σύνορο απόφασης πλησιάζει την λιγότερη πιθανή κλάση, άρα ο κανόνας αποφασίζει περισσότερο υπέρ της πιθανότερης κλάσης.



Σχήμα 16 : Σύνоро απόφασης για τους διαφορετικούς πίνακες συνδιασποράς, με τις ισοϋψείς καμπύλες πάνω δεξιά να ανήκουν στο  $\omega_2$  και τις ισοϋψείς καμπύλες στο κέντρο να ανήκουν στο  $\omega_1$

Υποθέτωντας ότι οι πίνακες συνδιασποράς είναι ίδιοι τότε ομοίως προκύπτει ότι :

$$\Sigma = \Sigma_1 = \Sigma_2 = \begin{pmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{pmatrix}$$

$$\mu_1 = \begin{bmatrix} 3 \\ 3 \end{bmatrix}, \quad \mu_2 = \begin{bmatrix} 6 \\ 6 \end{bmatrix}$$

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^T \Sigma^{-1}(x - \mu_i) + \ln P(\omega_i)$$

$$g_i(x) = w_i^T x + w_{i0}$$

$$w_i = \Sigma^{-1} \mu_i$$

$$w_{i0} = -\frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i + \ln P(\omega_i)$$

$$g_1(x) = w_1^T x + w_{10}$$

$$w_1 = \Sigma^{-1} \mu_1 = \frac{1}{1.28} \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix} \begin{bmatrix} 3 \\ 3 \end{bmatrix} = \begin{pmatrix} \frac{1.2}{1.28} & \frac{-0.4}{1.28} \\ \frac{-0.4}{1.28} & \frac{1.2}{1.28} \end{pmatrix} \begin{bmatrix} 3 \\ 3 \end{bmatrix} = \begin{bmatrix} \frac{3.6-1.2}{1.28} \\ \frac{-1.2+3.6}{1.28} \end{bmatrix} = \begin{bmatrix} \frac{2.4}{1.28} \\ \frac{2.4}{1.28} \end{bmatrix}$$

$$w_{10} = -\frac{1}{2} \begin{bmatrix} 3 \\ 3 \end{bmatrix}^T \frac{1}{1.28} \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix} \begin{bmatrix} 3 \\ 3 \end{bmatrix} + \ln P(\omega_1) = -\frac{1}{2} (3 \quad 3) \begin{bmatrix} \frac{2.4}{1.28} \\ \frac{2.4}{1.28} \end{bmatrix} + \ln P(\omega_1) = -\frac{7.2}{1.28} \ln P(\omega_1)$$

$$g_2(x) = w_2^T x + w_{20}$$

$$w_2 = \Sigma^{-1} \mu_2 = \frac{1}{1.28} \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix} \begin{bmatrix} 6 \\ 6 \end{bmatrix} = \begin{pmatrix} \frac{1.2}{1.28} & \frac{-0.4}{1.28} \\ \frac{-0.4}{1.28} & \frac{1.2}{1.28} \end{pmatrix} \begin{bmatrix} 6 \\ 6 \end{bmatrix} = \begin{bmatrix} \frac{7.2-2.4}{1.28} \\ \frac{-2.4+7.2}{1.28} \end{bmatrix} = \begin{bmatrix} \frac{4.8}{1.28} \\ \frac{4.8}{1.28} \end{bmatrix}$$

$$w_{20} = -\frac{1}{2} \begin{bmatrix} 6 \\ 6 \end{bmatrix}^T \frac{1}{1.28} \begin{pmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{pmatrix} \begin{bmatrix} 6 \\ 6 \end{bmatrix} + \ln P(\omega_2) = -\frac{1}{2} (6 \quad 6) \begin{bmatrix} \frac{4.8}{1.28} \\ \frac{4.8}{1.28} \end{bmatrix} + \ln P(\omega_2) = -\frac{28.8}{1.28} \ln P(\omega_2)$$

$$\begin{aligned} g_1(x) > g_2(x) &\Leftrightarrow w_1^T x + w_{10} > w_2^T x + w_{20} \Leftrightarrow (w_1^T - w_2^T)x + w_{10} - w_{20} > 0 \Leftrightarrow \\ \left( -\frac{2.4}{1.28} \quad -\frac{2.4}{1.28} \right) \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 16.875 + \ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) > 0 &\Leftrightarrow \left( -\frac{2.4}{1.28} \right) x_1 + \left( -\frac{2.4}{1.28} \right) x_2 + 16.875 + \ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) > 0 \Leftrightarrow \\ x_1 + x_2 - 9 - 0.533 \ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) < 0 &\Leftrightarrow x_1 + x_2 < 9 + 0.533 \ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) \end{aligned}$$

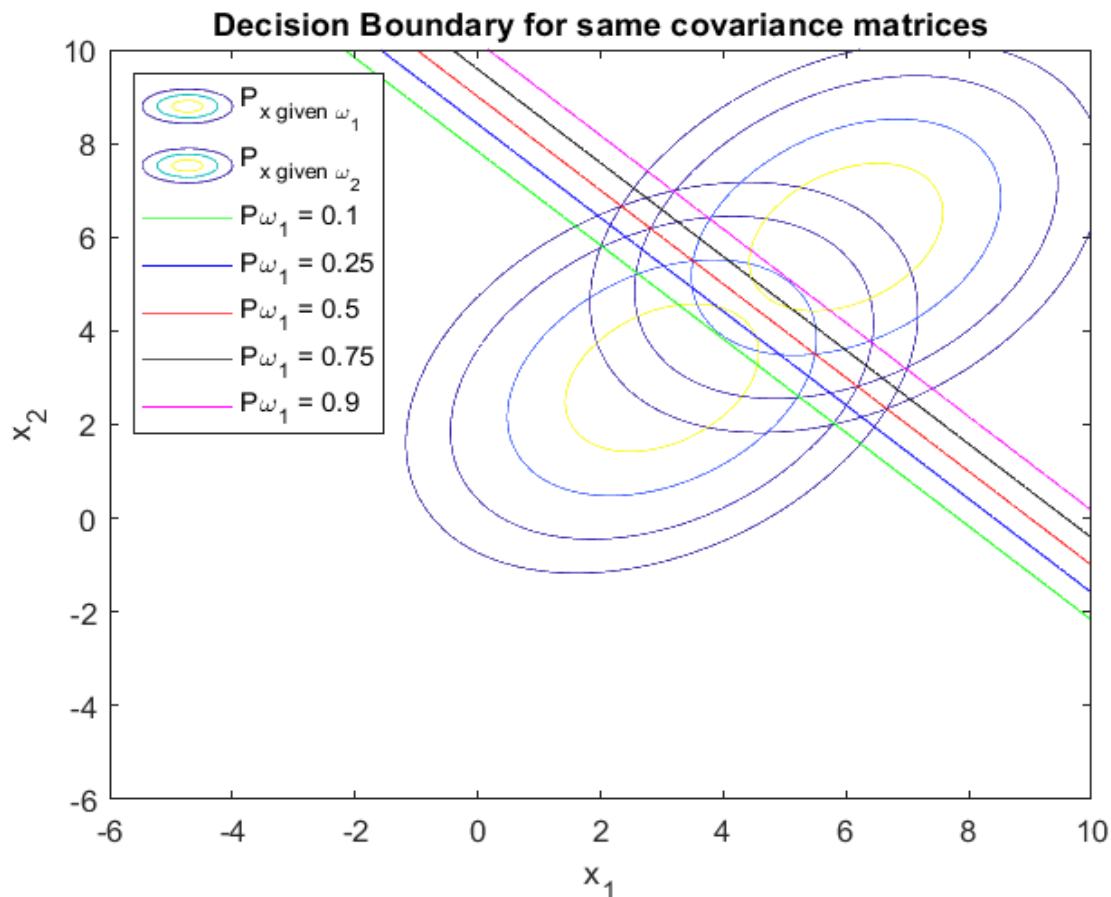
Άρα το σύνορο απόφασης είναι  $x_1 + x_2 < 9 + 0.533 \ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right)$ .

Στο σχήμα 17 έχουν σχεδιαστεί μερικές ισοϋψείς καμπύλες των δεσμευμένων πιθανοτήτων

$p(x|\omega_i) \in \mathcal{R}$  για κάθε κλάση  $i$  μαζί με τα σύνορα απόφασης για τις ακόλουθες τιμές των a-priori πιθανοτήτων  $P(\omega_1) = 0.1, 0.25, 0.5, 0.75, 0.9$  και  $P(\omega_2) = 1 - P(\omega_1)$ . Τα σύνορα απόφασης που προκύπτουν είναι ευθείες γραμμές με αρνητική κλίση, το οποίο επαληθεύεται τόσο από τον θεωρητικό τύπο όσο και από τη σχεδίαση τους. Επίσης το σύνορο απόφασης μπορεί να γραφεί ως:

$$x_1 + x_2 < 9 + 0.533 \ln \frac{P(\omega_1)}{1 - P(\omega_1)} \quad (b)$$

Παρατηρείται στο σχήμα 17 ότι αυξάνοντας την εκ των προτέρων πιθανότητα  $P(\omega_1)$  μειώνεται προφανώς η εκ των προτέρων πιθανότητα  $P(\omega_2)$  και το σύνορο απόφασης μετατίθεται σε πιο υψηλές τιμές αφού αυξάνεται το δεξιό μέλος της ανισότητας b. Επίσης όσο αυξάνεται η  $P(\omega_1)$  το σύνορο απόφασης πλησιάζει την λιγότερη πιθανή κλάση, άρα ο κανόνας αποφασίζει περισσότερο υπέρ της πιθανότερης κλάσης.





Σχήμα 17 : Σύνορο απόφασης για ίδιους πίνακες συνδιασποράς με τις ισοϋψείς καμπύλες πάνω δεξιά να ανήκουν στο  $\omega_2$  και τις ισοϋψείς καμπύλες στο κέντρο να ανήκουν στο  $\omega_1$

## Θέμα 5: Εξαγωγή χαρακτηριστικών και Bayes Classification

Στην 5η άσκηση υλοποιήθηκε ο υπολογισμός ενός χαρακτηριστικού για ορισμένες χειρόγραφες εικόνες οι οποίες αναπαριστούν ψηφία από το 0 μέχρι το 9 και λαμβάνονται από ένα dataset. Συγκεκριμένα πραγματοποιήθηκε ο υπολογισμός του aspect ratio για τα ψηφία 1 και 2, ο οποίος ορίζεται ως εξής:

$aspect\_ratio = width / height$  όπου το  $width$  και  $height$  είναι το μήκος και το ύψος του ελάχιστου ορθογωνίου που περικλείει ένα ψηφίο αντίστοιχα.

Αρχικά γίνεται η φόρτωση των δεδομένων και υπολογίζεται για τις εικόνες των ψηφίων 1,2 των δεδομένων εκπαίδευσης το aspect ratio κάθε μιας με τη χρήση της συνάρτησης `compute_aspect_ratio`. Η συνάρτηση υπολογισμού του aspect ratio έχει υλοποιηθεί με τη λογική του ελάχιστου ορθογωνίου το οποίο περιβάλλει την αντίστοιχη εικόνα. Στη συνέχεια εκτυπώνονται ενδεικτικά δύο δείγματα από τα δύο ψηφία ένα από το καθένα τα οποία περιβάλλει το ελάχιστο ορθογώνιο (Bounding Box).



Από όλα τα δεδομένα εκπαίδευσης των ψηφίων 1,2 υπολογίζονται τα  $\min\text{AspectRatio}$  και  $\max\text{AspectRatio}$  τα οποία είναι αντίστοιχα η ελάχιστη και η μέγιστη τιμή του λόγου όψεως από όλες τις εικόνες.

Υλοποιώντας έναν Naive Bayes ταξινομητή ο οποίος βασίζεται στην εφαρμογή του θεωρήματος του Bayes πραγματοποιείται η εκτίμηση της κλάσης που ανήκουν τα δείγματα ελέγχου. Ο Naive Bayes ταξινομητής χρησιμοποιεί τις εκ των υστέρων (a-posteriori) πιθανότητες, οι οποίες υπολογίστηκαν από τα δεδομένα εκπαίδευσης (a-priori) και ελέγχου (Likelihood), για να εκτιμήσει σε ποιά κλάση ανήκει το εκάστοτε δείγμα ελέγχου. Συγκεκριμένα ο ταξινομητής επιλέγει ότι το δείγμα ανήκει στη κλάση του ψηφίου 1 αν η εκ των υστέρων πιθανότητα του ψηφίου 1 είναι μεγαλύτερη από την εκ των υστέρων πιθανότητα του ψηφίου 2, αλλιώς επιλέγει ότι το δείγμα ανήκει στη κλάση του ψηφίου 2. Τέλος υπολογίστηκε το σφάλμα εκτίμησης ως το ποσοστό των λανθασμένων αποφάσεων του ταξινομητή στο σύνολο των δειγμάτων ελέγχου το οποίο είναι 10.93%.

## Θέμα 6ο : Minimum risk

$$P(\omega_1) = P(\omega_2)$$

$$p(x|\omega_i) = \begin{cases} \frac{x}{\sigma_i^2} \cdot e^{\frac{-x^2}{2 \cdot \sigma_i^2}}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Ισχύει ότι  $\sigma_1=1, \sigma_2=2$  και ο πίνακας

$$L = \begin{pmatrix} 0 & 0.5 \\ 1.0 & 0 \end{pmatrix}$$

Με το κριτήριο ελαχιστοποίησης μέσου ρίσκου για δύο κλάσεις η ταξινόμηση γίνεται με βάση τις ποσότητες :

$$l_1 = \lambda_{11} \cdot P(\omega_1) \cdot P(x|\omega_1) + \lambda_{21} \cdot P(\omega_2) \cdot P(x|\omega_2)$$

$$l_2 = \lambda_{12} \cdot P(\omega_1) \cdot P(x|\omega_1) + \lambda_{22} \cdot P(\omega_2) \cdot P(x|\omega_2)$$

Ταξινομούμε το  $x$  στην κλάση  $\omega_1$  αν το  $l_1 < l_2$  και στην κλάση  $\omega_2$  αν το  $l_1 > l_2$ . Άρα το σημείο διαχωρισμού (το κατώφλι  $x_o$ ) είναι εκεί που:

$$l_1 = l_2 \Leftrightarrow \lambda_{11} \cdot P(\omega_1) \cdot P(x|\omega_1) + \lambda_{21} \cdot P(\omega_2) \cdot P(x|\omega_2) = \lambda_{12} \cdot P(\omega_1) \cdot P(x|\omega_1) + \lambda_{22} \cdot P(\omega_2) \cdot P(x|\omega_2)$$

$$\Leftrightarrow 0 + \lambda_{21} \cdot P(\omega_2) \cdot P(x|\omega_2) = \lambda_{12} \cdot P(\omega_1) \cdot P(x|\omega_1) + 0 \Leftrightarrow \frac{P(x|\omega_1)}{P(x|\omega_2)} = \frac{\lambda_{21} \cdot P(\omega_2)}{\lambda_{12} \cdot P(\omega_1)} \quad (3)$$

Ακομή είναι γνωστό ότι οι εκ των προτέρων (a priori) πιθανότητες των δύο κλάσεων είναι ίσες δηλαδή ισχύει ότι  $P(\omega_1) = P(\omega_2)$ . Άρα

$$(3) \Rightarrow \ln\left(\frac{P(x|\omega_1)}{P(x|\omega_2)}\right) = \ln\left(\frac{\lambda_{21}}{\lambda_{12}}\right) \Leftrightarrow \ln P(x|\omega_1) - \ln P(x|\omega_2) = \ln\left(\frac{\lambda_{21}}{\lambda_{12}}\right) \Leftrightarrow \ln\left(\frac{x}{\sigma_1^2} \cdot e^{\frac{-x^2}{2\sigma_1^2}}\right) - \ln\left(\frac{x}{\sigma_2^2} \cdot e^{\frac{-x^2}{2\sigma_2^2}}\right) = \ln\left(\frac{\lambda_{21}}{\lambda_{12}}\right)$$

$$\Leftrightarrow \ln\left(\frac{x}{2\sigma_1^2}\right) - \frac{x}{2\sigma_1^2} - \ln\left(\frac{x}{2\sigma_2^2}\right) + \frac{x}{2\sigma_2^2} = \ln\left(\frac{\lambda_{21}}{\lambda_{12}}\right) \Leftrightarrow \ln\left(\frac{\frac{x}{2\sigma_1^2}}{\frac{x}{2\sigma_2^2}}\right) - \frac{x}{2\sigma_1^2} + \frac{x}{2\sigma_2^2} = \ln\left(\frac{\lambda_{21}}{\lambda_{12}}\right)$$

$$\Leftrightarrow 2 \cdot \ln\left(\frac{\sigma_2}{\sigma_1}\right) + x^2\left(\frac{1}{\sigma_2^2} - \frac{1}{\sigma_1^2}\right) = \ln\left(\frac{\lambda_{21}}{\lambda_{12}}\right) \Leftrightarrow 2 \cdot \ln 2 + x^2\left(\frac{1}{8} - \frac{1}{2}\right) = \ln 2 \Leftrightarrow x^2 \cdot \left(\frac{-3}{8}\right) = -\ln 2$$

$$\Leftrightarrow x^2 = \frac{8}{3} \cdot \ln 2 \Rightarrow x = \sqrt{\frac{8}{3} \cdot \ln 2}$$

Άρα το σύννορο απόφασης ισούται με  $x_o = \sqrt{\frac{8}{3} \cdot \ln 2}$ .

### ΘΕΜΑ 7ο : Singular Value Decomposition (SVD)

$$X = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 3 \end{bmatrix}$$

1)

Η ιδιοανάλυση του πίνακα  $X^T \cdot X$  :

$$A = X^T \cdot X = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 1 & 3 \end{bmatrix} \cdot \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 6 & 7 \\ 7 & 14 \end{bmatrix}$$

$$A - \lambda I = \begin{bmatrix} 6-\lambda & 7 \\ 7 & 14-\lambda \end{bmatrix}$$

Έυρεση των ιδιοτιμών του πίνακα

$$\det(A - \lambda I) = 0 \Rightarrow \begin{bmatrix} 6-\lambda & 7 \\ 7 & 14-\lambda \end{bmatrix} = 0 \Rightarrow (6-\lambda) \cdot (14-\lambda) - 49 = 0 \Rightarrow (6-\lambda) \cdot (14-\lambda) = 49$$

$$6 \cdot 14 - 14 \cdot \lambda - 6 \cdot \lambda + \lambda^2 = 49 \Rightarrow \lambda^2 - 20 \cdot \lambda + 35 = 0 \Rightarrow \lambda = \frac{+20 \pm \sqrt{(260)}}{2} \Rightarrow \lambda = +10 \pm \sqrt{(65)} \Rightarrow$$

$$\lambda_{1,2} = +10 \pm \sqrt{(65)} \Rightarrow \lambda_1 = 18.062, \lambda_2 = 1.937$$

Έυρεση των ιδιοδιανυσμάτων του πίνακα A

Για  $\lambda_1 = 18.062$ :

$$(A - \lambda_1) \cdot X = 0 \Rightarrow \begin{bmatrix} 6-18.062 & 7 \\ 7 & 14-18.062 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \Rightarrow \begin{bmatrix} -12.062 & 7 \\ 7 & -4.062 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$$

$$-12.062 \cdot x_1 + 7 \cdot x_2 = 0 \Rightarrow 7 \cdot x_2 = 12.062 \cdot x_1 \Rightarrow x_2 = \frac{12.062}{7} \cdot x_1 \Rightarrow x_2 = 1.723 \cdot x_1$$

$$7 \cdot x_1 - 4.062 \cdot x_2 = 0 \Rightarrow 7 \cdot x_1 = 4.062 \cdot x_2 \Rightarrow x_2 = \frac{7}{4.062} \cdot x_1 \Rightarrow x_2 = 1.723 \cdot x_1$$

$$X_1 = \begin{bmatrix} 0.58 \\ 1 \end{bmatrix} \cdot t$$

Για  $\lambda_2 = 1.937$ :

$$(A - \lambda_2) \cdot X = 0 \Rightarrow \begin{bmatrix} 6-1.937 & 7 \\ 7 & 14-1.937 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \Rightarrow \begin{bmatrix} 4.063 & 7 \\ 7 & 12.063 \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$$

$$4.063 \cdot x_1 + 7 \cdot x_2 = 0 \Rightarrow 7 \cdot x_2 = -4.063 \cdot x_1 \Rightarrow x_2 = \frac{-4.063}{7} \cdot x_1 \Rightarrow x_2 = -0.580 \cdot x_1$$

$$7 \cdot x_1 + 12.063 \cdot x_2 = 0 \Rightarrow 7 \cdot x_1 = -12.063 \cdot x_2 \Rightarrow x_2 = \frac{7}{-12.063} \cdot x_1 \Rightarrow x_2 = -0.580 \cdot x_1$$

$$X_2 = \begin{bmatrix} -1.723 \\ 1 \end{bmatrix} \cdot t$$

**2)** Έυρεση των singular values οι οποίες σχηματίζουν το πίνακα Σ

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{10 + \sqrt{65}} = 4.250$$

$$\sigma_2 = \sqrt{\lambda_2} = \sqrt{10 - \sqrt{65}} = 1.392$$

**3)** Έυρεση των μη αρνητικών ιδιοδιανυσμάτων του πίνακα  $X \cdot X^T$  :

$$u_1 = \frac{1}{\sqrt{\lambda_1}} \cdot X \cdot v_1 = \frac{1}{4.25} \cdot \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 3 \end{bmatrix} \cdot \begin{bmatrix} 0.58 \\ 1 \end{bmatrix} \Rightarrow u_1 = \frac{1}{4.25} \cdot \begin{bmatrix} 0.58 + 2 \cdot 1 \\ 2 \cdot 0.58 + 1 \\ 0.58 + 3 \cdot 1 \end{bmatrix} \Rightarrow u_1 = \frac{1}{4.25} \cdot \begin{bmatrix} 2.58 \\ 2.16 \\ 3.58 \end{bmatrix} \Rightarrow$$

$$u_1 = \begin{bmatrix} 0.607 \\ 0.508 \\ 0.842 \end{bmatrix}$$

$$u_2 = \frac{1}{\sqrt{\lambda_2}} \cdot X \cdot v_2 = \frac{1}{1.392} \cdot \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 3 \end{bmatrix} \cdot \begin{bmatrix} -1.723 \\ 1 \end{bmatrix} \Rightarrow u_2 = \frac{1}{1.392} \cdot \begin{bmatrix} -1.723 + 2 \cdot 1 \\ 2 \cdot (-1.723) + 1 \\ -1.723 + 3 \cdot 1 \end{bmatrix} \Rightarrow u_2 = \frac{1}{1.392} \cdot \begin{bmatrix} 0.277 \\ -2.446 \\ 1.277 \end{bmatrix} \Rightarrow$$

$$u_2 = \begin{bmatrix} -0.199 \\ -1.757 \\ 0.917 \end{bmatrix}$$

**4)**

$$X = U \cdot \Sigma \cdot V^T = \begin{bmatrix} 0.607 & -0.199 \\ 0.508 & -1.757 \\ 0.842 & 0.917 \end{bmatrix} \cdot \begin{bmatrix} 4.25 & 0 \\ 0 & 1.392 \end{bmatrix} \cdot \begin{bmatrix} 0.58 & 1 \\ -1.723 & 1 \end{bmatrix}$$

Επομένως η καλύτερη rank-1 προσέγγιση του πίνακα X είναι :

$$X_{rank-1} = 4.25 \cdot \begin{bmatrix} 0.607 \\ 0.508 \\ 0.842 \end{bmatrix} \cdot \begin{bmatrix} 0.58 & 1 \end{bmatrix} \Rightarrow$$

$$X_{rank-1} = \begin{bmatrix} 1.496 & 2.579 \\ 1.252 & 2.159 \\ 2.075 & 3.578 \end{bmatrix}$$

#### Διευκρινίσεις πάνω στο κώδικα :

Στους κώδικες που περιέχονται στο .zip αρχείο μαζί με την παρούσα αναφορά κρίνεται αναγκαίο να διευκρινιστούν κάποια κομμάτια κώδικα. Το πρώτο είναι στο 2ο μέρος του 1ου θέματος, στο οποίο ζητείται να επαναληφθεί η διαδικασία που προηγήθηκε για διαφορετικών αριθμό κύριων συνιστωσών ( $K=10, 50, 200$ ). Αυτό έχει υλοποιηθεί χειροκίνητα, συγκεκριμένα θέτοντας τις τιμές των σταθερών στις γραμμές 153 και 169 στο αρχείο 'ex1\_1\_pca.m' στις επιθυμητές τιμές. Το άλλο είναι ότι για τη σχεδίαση των συνόρων απόφασης και των ισοϋψών καμπυλών των δεσμευμένων πιθανοτήτων υλοποιήθηκε κώδικας σε matlab ο οποίος βρίσκεται στο φάκελο 'exercise1\_4.m'.